

Predicción y Segmentación Dinámica del Mercado Inmobiliario en NYC

Informe Técnico Completo del Proyecto

Autor: Sergio Minguez Cruces

Institución: UNIE Universidad

Grado: Matemáticas

Asignatura: Minería de Datos

14 de Mayo de 2026

Resumen

Este informe detalla el diseño, implementación y evaluación de un pipeline de *Minería de datos* sobre los alquileres de Airbnb en la ciudad de Nueva York (2019). El proyecto realiza un análisis de casi 50,000 propiedades, abordando problemas de asimetría de datos, valores faltantes condicionales (MAR), ect. Mediante ingeniería de variables (distancias geoespaciales), técnicas de reducción de dimensionalidad (PCA), y un ecosistema de modelización supervisada robusto (lineales, flexibles y ensembles), se logró un modelo generalizable ($R^2 \approx 59\%$) para la predicción de precios. De manera complementaria, el aprendizaje no supervisado (K-Means) ha permitido segmentar la oferta en nichos de mercado claramente definidos. Todo el sistema sigue una adherencia estricta a principios de reproducibilidad y culmina en el despliegue de una herramienta interactiva.

Índice

1. Introducción y Motivación	4
1.1. Contextualización del Proyecto	4
1.2. Identificación del Problema de Negocio	4
1.3. Objetivos del Proyecto	4
1.4. Disponibilidad del Código y Reproduccion	4
2. Análisis Exploratorio de Datos (EDA)	5
2.1. Descripción General del Conjunto de Datos	5
2.1.1. Variables de Identificación	5
2.1.2. Variables Geográficas	6
2.1.3. Variables del Alojamiento	6
2.1.4. Variables Numéricas	6
2.1.5. Variable Temporal	7
2.2. Tratamiento de Valores Faltantes y Naturaleza MAR	7
2.3. Análisis de Distribuciones y Asimetría Severa	8
2.4. Análisis de datos anómalos	9
3. Ingeniería de Variables	10
3.1. Creación de Features Espaciales	10
3.2. Codificación	10
3.3. Reducción de Dimensionalidad: Análisis de Componentes Principales (PCA) . . .	11
4. Aprendizaje No Supervisado: Segmentación de Mercado	12
4.1. Metodología de Clustering	12
4.2. Determinación por Consenso del Número Óptimo de Clústeres (K)	12
4.3. Perfilado y Caracterización	14
5. Aprendizaje Supervisado: Modelado Predictivo	15
5.1. Diseño Experimental y Ecosistema de Modelos	15
5.2. Optimización de Hiperparámetros (GridSearchCV)	16
5.3. Métricas de Evaluación	16
5.4. Análisis de Curvas de Aprendizaje	17
5.5. Análisis de Importancia de Variables (Feature Importance)	19
5.5.1. Metodología de Cálculo	20
5.5.2. Interpretación de Resultados y Predominancia de Componentes	20
5.6. Evaluación, Diagnóstico y Selección Final	21

6. Despliegue e Interfaz Interactiva	22
6.1. Arquitectura de Producción (Streamlit)	22
6.2. Estructura Modular del Aplicativo	23
6.3. Visualización Avanzada de Segmentación	23
6.4. El Motor de Inferencia y Simulación	24
7. Conclusiones y Trabajo Futuro	24
7.1. Cumplimiento de Objetivos	24
7.2. Limitaciones del Estudio	25
7.3. Recomendaciones y Trabajo Futuro	25

1. Introducción y Motivación

1.1. Contextualización del Proyecto

La ciudad de Nueva York representa uno de los ecosistemas inmobiliarios y turísticos más densos, dinámicos y competitivos a nivel mundial. Con millones de visitantes anuales, plataformas de alojamiento compartido como Airbnb han revolucionado la manera en que se distribuye y consume el espacio habitable temporal. El conjunto de datos analizado en este trabajo, *New York City Airbnb Open Data* de 2019 (?), captura una radiografía transversal de este fenómeno, conteniendo información detallada de casi 50,000 listados activos.

1.2. Identificación del Problema de Negocio

Para una plataforma bilateral como Airbnb, mantener el equilibrio entre la oferta (anfitriones) y la demanda (huéspedes) es fundamental para la maximización de ingresos. Un problema persistente en este ecosistema es la **correcta valoración del precio** de las propiedades. Los anfitriones novatos a menudo carecen del conocimiento del mercado para fijar precios competitivos, lo que resulta en tasas de ocupación subóptimas (si el precio es excesivo) o pérdida de ganancias potenciales (si el precio es deficiente).

Este proyecto aborda la necesidad de crear un motor algorítmico capaz de estimar el valor intrínseco de un alojamiento basándose estrictamente en sus características observables.

1.3. Objetivos del Proyecto

El desarrollo técnico de este informe se estructuró para dar cumplimiento a tres objetivos analíticos principales:

1. **Predicción de Precios en NYC (Supervisado):** Construir, optimizar y contrastar una batería extensa de modelos de regresión (desde modelos lineales penalizados hasta métodos de *ensembles* avanzado incluyendo modelos flexibles) para predecir el precio del alojamiento.
2. **Inteligencia Espacial (Ingeniería de Variables):** Trascender la simple pertenencia a un vecindario mediante el cálculo de distancias reales a puntos neurálgicos de la ciudad, transformando metadatos de latitud y longitud en variables predictivas robustas.
3. **Segmentación de Mercado (No Supervisado):** Implementar un proceso de agrupación algorítmica para descubrir submercados latentes dentro de NYC, perfilando la oferta más allá de divisiones administrativas, lo que permite detectar patrones de demanda y concentración de opciones *premium* versus económicas.

Para garantizar un rigor estadístico absoluto y reproducibilidad, el proyecto completo (desde el remuestreo inicial hasta el *GridSearchCV*) ha sido anclado mediante un estricto control estocástico (`random_state=42`).

1.4. Disponibilidad del Código y Reproducción

Para garantizar la transparencia de los procesos de cálculo y permitir la replicabilidad de los resultados obtenidos, incluyendo los scripts de preprocesamiento, el entrenamiento de los 12 modelos y la arquitectura de la aplicación Streamlit ha sido alojado en el repositorio público de GitHub:

https://github.com/Sergio-repogit/NYC_reg_model_clustering

2. Análisis Exploratorio de Datos (EDA)

2.1. Descripción General del Conjunto de Datos

El conjunto de datos original cuenta con 48,895 registros y 16 variables que engloban tanto identificadores nominales, métricas temporales, como coordenadas geográficas continuas. Antes de someter estos datos a cualquier transformación predictiva, se realizó un Análisis Exploratorio de Datos (EDA) para diagnosticar problemas estructurales de asimetría, colinealidad y valores perdidos.

2.1.1. Variables de Identificación

Tabla 1: Variables de Identificación

Variable	Tipo	Descripción
id	Entero	Identificador único de la propiedad. Rango: [2,539 – 36,487,245]. No hay valores duplicados ni faltantes.
name	Texto	Nombre descriptivo del alojamiento proporcionado por el anfitrión. Contiene 47,905 valores únicos con 16 valores faltantes (0.03 %).
host_id	Entero	Identificador único del anfitrión. Hay 37,457 anfitriones distintos, lo que indica que algunos gestionan múltiples propiedades. Rango: [2,438 – 274,321,313].
host_name	Texto	Nombre del anfitrión. Contiene 11,452 nombres únicos con 21 valores faltantes (0.04 %). Los nombres más comunes son Michael (417), David (403) y Sonder (NYC) (327).

2.1.2. Variables Geográficas

Tabla 2: Variables Geográficas

Variable	Tipo	Descripción
neighbourhood_group	Categorica	Distrito administrativo de Nueva York. Contiene 5 valores únicos sin datos faltantes: Manhattan (44.30 %), Brooklyn (41.12 %), Queens (11.59 %), Bronx (2.23 %) y Staten Island (0.76 %).
neighbourhood	Categorica	Vecindario específico dentro del distrito. Hay 221 vecindarios distintos. Los más frecuentes son Williamsburg (8.02 %), Bedford-Stuyvesant (7.60 %) y Harlem (5.44 %).
latitude	Continua	Coordenada de latitud de la propiedad en grados decimales. Rango: [40.50 – 40.91]. Media: 40.73 (± 0.05). Contiene 19,048 valores únicos.
longitude	Continua	Coordenada de longitud de la propiedad en grados decimales. Rango: [-74.24 – -73.71]. Media: -73.95 (± 0.05). Contiene 14,718 valores únicos.

2.1.3. Variables del Alojamiento

Tabla 3: Variables del Alojamiento

Variable	Tipo	Descripción
room_type	Categorica	Tipo de alojamiento ofrecido. Contiene 3 categorías sin valores faltantes: ▪ <i>Entire home/apt</i> (51.97 %): Apartamento o casa completa ▪ <i>Private room</i> (45.66 %): Habitación privada ▪ <i>Shared room</i> (2.37 %): Habitación compartida

2.1.4. Variables Numéricas

price (Variable Objetivo): Precio por noche del alojamiento en dólares estadounidenses. Presenta una distribución altamente asimétrica con presencia de valores extremos. La mediana (\$106) es considerablemente menor que la media (\$152.72), indicando sesgo positivo. Existe un 25 % de propiedades con precio inferior a \$69 y un 25 % superior a \$175. Se observan valores anómalos como precios de \$0 (asociados a intercambios de alojamientos, habitual en estas plataformas) y el valor máximo de \$10,000.

minimum_nights: Número mínimo de noches requerido para reservar la propiedad. La mayoría de los alojamientos (75 %) requieren 5 noches o menos, siendo la mediana de 3 noches. Sin

embargo, existe gran variabilidad (desviación estándar de 20.51) debido a propiedades con requisitos extremos (máximo de 1,250 noches), indicando alojamientos de larga duración.

number_of_reviews: Número total histórico de reseñas recibidas por la propiedad. La mediana de 5 reseñas contrasta con una media de 23.27, evidenciando una distribución sesgada. Un 25 % de las propiedades tienen 1 reseña o menos, mientras que el valor máximo alcanza 629 reseñas.

reviews_per_month: Tasa promedio de reseñas recibidas por mes. Esta variable presenta 10,052 valores faltantes (20.56 %), coincidentes exactamente con las propiedades que carecen de fecha en **last_review**, lo cual sugiere que representan alojamientos nuevos sin historial de reseñas. La distribución es altamente asimétrica (media 1.37 vs mediana 0.72).

calculated_host_listings_count: Número total de propiedades que el anfitrión tiene listadas en Airbnb. La mediana de 1 indica que la mayoría de los anfitriones gestionan una sola propiedad, aunque existen hosts profesionales con hasta 327 listados. Esta variable permite identificar anfitriones comerciales versus particulares.

availability_365: Número de días disponibles para reserva durante el año siguiente. Presenta gran variabilidad (media 112.78, mediana 45) con valores que abarcan desde 0 (no disponible) hasta 365 días (disponible todo el año). Un 25 % de las propiedades reportan disponibilidad de 0 días.

Tabla 4: Estadísticas Descriptivas de Variables Numéricas

Variable	Media	Mediana	Desv. Est.	Min	Q1	Q3	Max
price	152.72	106.00	240.15	0	69.00	175.00	10,000
minimum_nights	7.03	3.00	20.51	1	1.00	5.00	1,250
number_of_reviews	23.27	5.00	44.55	0	1.00	24.00	629
reviews_per_month*	1.37	0.72	1.68	0.01	0.19	2.02	58.50
calculated_host_listings_count	7.14	1.00	32.95	1	1.00	2.00	327
availability_365	112.78	45.00	131.62	0	0.00	227.00	365

*Presenta 10,052 valores faltantes (20.56 %)

2.1.5. Variable Temporal

Tabla 5: Variable Temporal

Variable	Tipo	Descripción
last_review	Fecha	Fecha de la última reseña recibida (formato YYYY-MM-DD). Contiene 1,764 fechas únicas con 10,052 valores faltantes (20.56 %), correspondientes a propiedades sin reseñas. Las fechas más frecuentes son 2019-06-23 (1,413 propiedades) y 2019-07-01 (1,359 propiedades).

2.2. Tratamiento de Valores Faltantes y Naturaleza MAR

La revisión reveló valores faltantes focalizados en cuatro columnas: **name**, **host_name**, **last_review** y **reviews_per_month**. Las dos primeras representan una pérdida negligente (menos del 0.05 %)

y al ser variables que van a ser eliminadas para el modelaje se optó por no imputarlas ya que no tendría utilidad.

El caso de `last_review` y `reviews_per_month` requirió un análisis diagnóstico más detallado. Se identificó que la falta de datos en estas variables no obedece a un error de recolección (MCAR, *Missing Completely At Random*), sino que corresponde a una estructura MAR (*Missing At Random*). Específicamente, existe una dependencia lógica entre estas variables son invariablemente nulas cuando la variable `number_of_reviews` es igual a 0. Esto significa que las propiedades que nunca han sido alquiladas o evaluadas carecen por definición de tasa de reseña mensual o fecha de última reseña. En base a esta evidencia, `reviews_per_month` fue imputado con 0, y `last_review` fue transformada en una nueva variable derivada que cuantifica los días desde la última interacción, asignando un umbral medio a los casos sin reseñas previas.

2.3. Análisis de Distribuciones y Asimetría Severa

El diagnóstico distribucional univariante mostro desviaciones significativas respecto a la normalidad en la amplia mayoría de las variables predictoras continuas y en la variable objetivo (`price`).

- **Variable Objetivo (`price`):** La distribución del precio presenta un severo sesgo a la derecha (*right skewness*), con una masa principal concentrada por debajo de los \$200 USD y valores atípicos extremos superando los \$10,000 USD. Para estabilizar la varianza y mejorar el comportamiento de los modelos lineales y paramétricos, se aplicó una transformación logarítmica $\log(1 + x)$ (conocida como `log1p`).
- **Variables Temporales y de Actividad:** Las variables `minimum_nights`, `number_of_reviews` y la derivada de recencia exhibieron un patrón de asimetría similar dictado por distribuciones de tipo Ley de Potencias. Por ende, la transformación `log1p` fue también aplicada a estos predictores.

Esta estandarización logarítmica mitiga sustancialmente la influencia desproporcionada de los valores atípicos sin necesidad de realizar recortes drásticos que suprimirían información valiosa (por ejemplo, listados genuinamente de lujo o penthouses).




Figura 1: Análisis univariante.

2.4. Análisis de datos anómalos

Tras el Análisis Exploratorio de Datos (EDA), se identificó la presencia de valores atípicos en prácticamente todas las variables numéricas del dataset (*price*, *number_of_reviews*, *minimum_nights*, etc.). En lugar de proceder a una eliminación mediante métodos estadísticos tradicionales como el Rango Inter cuartílico (IQR) o Z-Score, se optó por su **preservación integral** basada en los siguientes fundamentos:

- **Coherencia Sistémica:** Los valores extremos no se presentan de forma aislada o errática, sino que guardan una correlación lógica entre sí. Por ejemplo, valores elevados en *price* suelen coexistir con ubicaciones geográficas específicas o tipos de habitación que representan la realidad del mercado inmobiliario de alta gama en Manhattan.

- **Riqueza de la Segmentación:** Dado que uno de los objetivos es el aprendizaje no supervisado mediante clústeres, los registros atípicos definen las fronteras de los nichos de mercado. Eliminar estos registros resultaría en una homogeneización artificial del dataset, eliminando la capacidad de identificar comportamientos de nicho (ej. anfitriones con alta rotación vs. propiedades de disponibilidad exclusiva).
- **Fidelidad del Dominio:** En minería de datos aplicada al urbanismo. Las propiedades con un número de reseñas excepcionalmente alto o precios singulares son componentes críticos para entender la dinámica de oferta y demanda en una metrópolis global.

Para compensar el impacto negativo que estos valores podrían tener en algoritmos sensibles a la escala, se ha priorizado el uso de **escaladores robustos** y modelos de **ensamblado basados en árboles**, los cuales gestionan de forma nativa las particiones en distribuciones asimétricas sin necesidad de sacrificar información.

3. Ingeniería de Variables

3.1. Creación de Features Espaciales

La ubicación cruda definida por latitud y longitud, si bien provee un marco de referencia absoluto, carece de semántica de negocio si no se interrelaciona con los puntos neurálgicos de la demanda turística de Nueva York.

Para dotar de inteligencia espacial al modelo, se cálculo las distancias en superficie. Se proyectó la distancia en kilómetros desde cada propiedad hacia tres focos principales de actividad económica y turística:

1. **Times Square** (Centro de la actividad turística y comercial).
2. **Central Park** (Atracción paisajística primaria).
3. **Grand Central Terminal** (Eje de interconexión logística del transporte).

3.2. Codificación

Los modelos matemáticos (especialmente los basados en cálculo de distancias como SVM y Regresión Lineal) no asimilan características textuales. La naturaleza de los datos categóricos dictó una estrategia de codificación híbrida:

- **One-Hot Encoding (OHE):** Aplicado a variables con baja cardinalidad como `neighbourhood_group` (5 valores) y `room_type` (3 valores), evitando la introducción de una jerarquía artificial inexistente.
- **Target Encoding:** Aplicado al vector `neighbourhood` (más de 220 valores nominales), sustituyendo el nombre del vecindario por el precio logarítmico medio del mismo. Esto colapsó la altísima dimensionalidad sin mermar la varianza y reteniendo su peso explicativo.

Para las variables numéricas se utilizó el escalador estándar (**StandardScaler**), que transforma cada variable para que tenga media cero y desviación estándar uno. Este tipo de normalización resulta especialmente útil para algoritmos sensibles a la escala de las variables, como los métodos basados en distancias o en optimización.

3.3. Reducción de Dimensionalidad: Análisis de Componentes Principales (PCA)

La expansión del dataset mediante el *Target Encoding* y las distancias espaciales, junto a las variables temporales preexistentes, incrementó sustancialmente el riesgo de multicolinealidad estructural (por ejemplo, la alta dependencia entre `availability_365` y métricas temporales de reservas).

Para reducir la señal del ruido, se aplicó el Análisis de Componentes Principales (PCA). PCA encuentra una transformación lineal ortogonal del espacio de características originales hacia un nuevo sistema de coordenadas donde la varianza se maximiza iterativamente.

La ecuación de proyección a un nuevo componente principal z_k a partir del vector estandarizado x es:

$$z_k = \mathbf{w}_k^T \mathbf{x} \quad (1)$$

Sujeto a la restricción ortogonal $\|\mathbf{w}_k\| = 1$.

En la implementación, se conservó un umbral de hiperparámetro fijado empíricamente en el 95 % de varianza explicada. Este abordaje permitió eliminar componentes residuales redundantes, acelerando el tiempo de convergencia (*training time*) de modelos complejos como *Support Vector Machines* en la fase predictiva y estableciendo un espacio para el *Clustering*.




Figura 2: Análisis de Pc.




Figura 3: Análisis de varianza acumulada.

4. Aprendizaje No Supervisado: Segmentación de Mercado

4.1. Metodología de Clustering

Se empleó el algoritmo **K-Means** operando estrictamente sobre el espacio latente reducido (generado por PCA), garantizando así que las distancias Euclidianas calculadas por el algoritmo estuviesen exentas del sesgo impuesto por magnitudes dispares o colinealidad intrínseca.

La función de coste a minimizar (Inercia o WCSS - *Within-Cluster Sum of Squares*) se define como:

$$J = \sum_{j=1}^k \sum_{i=1}^n \|x_i^{(j)} - c_j\|^2 \quad (2)$$

4.2. Determinación por Consenso del Número Óptimo de Clústeres (K)

La dependencia analítica a un único método heurístico (e.g., Regla del Codo) para la selección de K puede inducir sesgos visuales e interpretativos severos. En este proyecto se usó una metodología de validación tripartita y unificada:

1. **Método del Codo (Elbow Method):** Análisis del punto de máxima curvatura sobre la curva de inercia decreciente, identificando el punto de saturación donde la ganancia marginal de añadir centroides adicionales colapsa.




Figura 4: Inercia según Número de Clusters

2. **Análisis de Silueta (Silhouette Score):** Maximización de la cohesión intra-cluster frente a la separación inter-cluster.




Figura 5: Silueta Promedio según Número de Clusters

3. **Estadístico Gap (Gap Statistic):** Comparación de la dispersión de los datos frente a una distribución nula aleatoria de referencia.




Figura 6: Estadístico GAP según Número de Clusters

A partir de estos tres cálculos, el algoritmo extrajo dinámicamente la mediana estadística (*Consensus K*) de las tres predicciones heurísticas, fijando la partición de la base de datos de manera agnóstica a intervenciones manuales.

Tabla 6: Evaluación de métricas para la selección de k

k	Inercia	Gap Statistic	Silhouette
2	586,893.02	3.3536	0.1014
3	546,820.62	3.3029	0.1158
4	493,659.45	3.3152	0.1364
5	450,079.66	3.3655	0.1376
6	429,922.42	3.3730	0.1487
7	396,553.58	3.4245	0.1500
8	382,565.42	3.4310	0.1485
9	346,584.38	3.5108	0.1761
10	325,766.90	3.5564	0.1741

Dada la complejidad y la alta dimensionalidad del mercado inmobiliario de NYC, un $k = 9$ ofrece un equilibrio óptimo entre *interpretabilidad de negocio* (segmentos lo suficientemente grandes para ser accionables) y *precisión matemática* (minimización de la varianza interna).

4.3. Perfilado y Caracterización

La segmentación resultante arrojó perfiles de mercado sustancialmente disímiles y dotados de semántica interpretable. La inyección de inteligencia analítica sobre los resultados permitió aislar las modas estadísticas de la variable `room_type` por cada clúster.

Tabla 7: Perfilamiento Táctico de Segmentos de Mercado (K-Means)

ID	Tipo de Habitación Dom.	% Tipo	Precio Medio	Dist. Centro	N
0	Entire home/apt	51.6 %	\$122.71	9.50 km	7,515
1	Entire home/apt	73.6 %	\$251.06	3.20 km	6,389
2	Private room	50.4 %	\$114.81	19.41 km	373
3	Private room	62.9 %	\$94.38	12.17 km	4,849
4	Private room	50.6 %	\$121.86	8.44 km	8,780
5	Private room	63.2 %	\$128.97	8.69 km	4,741
6	Entire home/apt	57.7 %	\$183.66	4.20 km	8,167
7	Entire home/apt	58.7 %	\$170.04	4.42 km	6,932
8	Shared room	100 %	\$70.22	7.85 km	1,149

Los hallazgos demuestran que el mercado neoyorquino está fuertemente fragmentado por una conjunción bivariente entre el tipo de habitación ofertada y el eje centralidad-precio. Se identificaron clústeres representativos de ofertas premium (habitaciones de tipo *Entire home/apt* de alto costo ubicados a mínimas distancias de los hitos espaciales) frente a clústeres residuales (mayoritariamente dominados en porcentaje por opciones *Shared room* o *Private room* en las periferias del Bronx o zonas externas de Queens y Brooklyn).

Este hallazgo es crucial: dictamina que una estrategia estandarizada de precios (*One-size-fits-all*) fracasaría inevitablemente, justificando la necesidad subyacente de emplear algoritmos de regresión flexibles capaces de emular ramificaciones condicionales.

5. Aprendizaje Supervisado: Modelado Predictivo

5.1. Diseño Experimental y Ecosistema de Modelos

El objetivo principal de la investigación residía en la construcción de un motor de inferencia capaz de aproximar la valoración económica del mercado inmobiliario, al ser una variable numérica continua los modelos serán de regresión.

Para asegurar el rigor, la evaluación se rigió bajo un paradigma de *Train-Test* (partición 80/20) asistido por **Cross-Validation** estructurada (K-Folds). Adicionalmente, todo el protocolo incluyó bloqueos de semillas (RANDOM_STATE=42) para imposibilitar la fuga de datos o discrepancias en la reproducibilidad.

Dada la heterogeneidad y los picos de no-linealidad expuestos en la fase de clustering, se entrenó masivamente un ecosistema integrado por 12 algoritmos distintos:

1. **Modelos de Regresión Lineal y Penalizados:** Regresión Lineal (Baseline), Regresión Ridge (penalización L_2) y Regresión Lasso (penalización L_1).
2. **Basados en Árboles:** Árbol de Decisión y RandomForestRegressor.
3. **Support Vector Machines:** LinearSVR y SVR con kernel Radial (SVR_RBF).
4. **Ensembles (Bagging y Boosting):** AdaBoost, XGBoost y Bagging sobre regresores SVR.
5. **Meta-Modelos (Ensamblajes de Alto Nivel):** Voting Regressor y Stacking Regressor (ensamblajes heterogéneos anidados).

5.2. Optimización de Hiperparámetros (GridSearchCV)

Para la optimización de hiperparámetros se empleó **validación cruzada estratificada** mediante **StratifiedKFold** de scikit-learn aplicado en el **GridSearchCV**.

El grid iteró sobre los principales parámetros de control de la arquitectura de red algorítmica: profundidades de árbol (**max_depth**), márgenes duros y blandos para el caso SVM (**C** y **gamma**), y coeficientes de penalización (α). Se usó el coeficiente de determinación (R^2) como métrica unificadora de convergencia en este espacio cartesiano paramétrico.

5.3. Métricas de Evaluación

Para cuantificar la eficacia de los modelos regresores y su capacidad de generalización, se ha seleccionado un conjunto de métricas que evalúan el error desde distintas perspectivas geométricas y estadísticas. A continuación, se formalizan las métricas empleadas, donde y_i representa el valor real, $\hat{y}_i$ el valor predicho y n el tamaño de la muestra.

1. **Coefficiente de Determinación (R^2):** Representa la proporción de la varianza total de la variable dependiente que es explicada por el modelo. Es una medida de la calidad del ajuste a los datos observados.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

Donde $\bar{y}$ es la media de los valores reales. Un R^2 cercano a 1 indica un ajuste óptimo, mientras que valores cercanos a 0 (o negativos) indican que el modelo no captura la estructura de los datos.

2. **Error Absoluto Medio (MAE):** Mide la magnitud promedio de los errores en un conjunto de predicciones, sin considerar su dirección. Es una métrica lineal donde todos los errores individuales tienen el mismo peso.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4)$$

En el contexto de este proyecto, el MAE es fundamental por su **interpretabilidad directa**, ya que expresa el error promedio en unidades monetarias (dólares).

3. **Error Cuadrático Medio de la Raíz (RMSE):** Es la raíz cuadrada del promedio de los errores al cuadrado. A diferencia del MAE, el RMSE penaliza de forma cuadrática las desviaciones grandes (outliers).

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5)$$

Se utiliza como un indicador de la estabilidad del modelo ante valores extremos, siendo una métrica más sensible a errores de gran magnitud.

4. **Overfitting Gap (Δ_{fit}):** Definida para este estudio como la diferencia absoluta entre el rendimiento en entrenamiento y validación.

$$\Delta_{fit} = R_{train}^2 - R_{test}^2 \quad (6)$$

Esta métrica permite diagnosticar el *trade-off* entre sesgo y varianza. Un Δ_{fit} elevado sugiere que el modelo ha memorizado el ruido del set de entrenamiento, perdiendo capacidad de generalización.

5.4. Análisis de Curvas de Aprendizaje

Las curvas de aprendizaje visualizan R^2 en train y validation en función del tamaño del conjunto de entrenamiento, permitiendo diagnosticar overfitting y determinar si más datos mejorarían el rendimiento.




Figura 7: Curva de aprendizaje de SVR.

Interpretaciones:

- **Convergencia:** El R^2 de entrenamiento y validación convergen asintóticamente conforme aumenta el tamaño del dataset, estabilizándose en un margen estrecho (gap $\approx 0,002$).
- **Aprendizaje Sostenido:** La pendiente positiva de la curva de validación sugiere que el modelo no ha llegado a la saturación total y sigue beneficiándose de la exposición a nuevos datos.
- **Estabilidad:** El estrechamiento del área sombreada (bandas de confianza) indica que el modelo es robusto y su varianza de estimación disminuye con el volumen de datos.
- **Comportamiento global:** Las curvas tienden a estabilizarse, lo que sugiere que añadir más datos podría seguir aportando mejoras marginales, pero no cambios drásticos en el rendimiento.

En conjunto, la curva de aprendizaje muestra un comportamiento de **buena generalización**, donde el modelo reduce progresivamente el sobreajuste inicial y converge hacia un rendimiento estable en validación.




Figura 8: Curva de aprendizaje de Volting.

Interpretaciones:

- **Complejidad Inicial:** A diferencia del modelo simple, el ensamblaje comienza con un R^2 en entrenamiento muy elevado ($> 0,75$), lo que refleja una alta capacidad expresiva inicial. Sin embargo, la convergencia es más lenta, manteniendo un *gap* residual final de $\approx 0,04$, sensiblemente superior al del SVR.
- **Saturación Prematura:** La pendiente de la curva de validación tiende aplanarse de forma más temprana, aproximadamente a partir de los 15,000 registros. Esto sugiere que el modelo llega a un punto de saturación donde la adición de más datos de la misma naturaleza apenas genera beneficios en la generalización.
- **Estabilidad de la Varianza:** El estrechamiento de las bandas de confianza es menos pronunciado que en el modelo SVR, lo que indica que el ensamblaje, al combinar modelos con diferentes sesgos, retiene una mayor incertidumbre intrínseca en sus estimaciones ante distintas particiones de los datos.
- **Comportamiento Global:** Las curvas muestran que, aunque el ensamblaje es un predictor potente, no logra la eficiencia asintótica del SVR. El *gap* persistente entre entrenamiento y validación sugiere que el modelo retiene una porción de varianza no explicada que podría derivar en un sobreajuste ligero si no se controla el volumen de datos.

Mientras que el SVR demuestra una convergencia casi óptima para este problema, el *Voting Assembly* presenta una estructura de aprendizaje más rígida que no logra trasladar toda su potencia de entrenamiento al entorno de validación con la misma fluidez, pero sigue por debajo del umbral de 0.05.




Figura 9: Curva de aprendizaje de Random Forest.

Interpretaciones:

- **Divergencia de Rendimiento (Gap):** A diferencia del SVR, este modelo presenta un **gap persistente** de $\approx 0,11$ al final del entrenamiento (descendiendo desde el 0,07 observado en validación cruzada inicial). Al superar el umbral estricto de estabilidad de 0,05 fijado en este estudio, el modelo se clasifica matemáticamente como **inestable**, evidenciando una incapacidad para generalizar la varianza capturada.
- **Alta Sensibilidad al Entrenamiento:** La curva roja comienza en valores de $R^2 > 0,80$, lo que indica que el algoritmo está memorizando patrones específicos y ruido del set de entrenamiento. Aunque esta curva desciende, nunca llega a converger con la de validación, manteniendo una distancia que compromete la fiabilidad de las predicciones en producción.
- **Saturación de la Capacidad de Generalización:** La curva de validación (verde) muestra un aplanamiento casi total a partir de los 15,000 registros, estabilizándose en un $R^2 \approx 0,56$. Esto sugiere que el modelo ha alcanzado un techo estructural: añadir más datos solo servirá para reducir ligeramente el error de entrenamiento, pero no mejorará su rendimiento ante casos nuevos.
- **Análisis de Varianza:** Las bandas de confianza, aunque estrechas, no compensan el sesgo de generalización. El modelo es 'seguro' en sus predicciones, pero consistentemente menos preciso de lo que su rendimiento en entrenamiento sugeriría.

El exceso de varianza detectado ($\text{Gap} > 0,05$) confirma que el modelo está sobreajustado a las particularidades del dataset de entrenamiento, resultando en un motor de inferencia menos robusto que la solución basada en SVR.

5.5. Análisis de Importancia de Variables (Feature Importance)

En esta fase, se analiza la relevancia de los componentes principales (PC_i) en la capacidad predictiva de los modelos. Este análisis es crucial para la *interpretabilidad del modelo*, permitiendo identificar qué combinaciones lineales de las variables originales de Airbnb poseen mayor peso en la determinación del precio.

5.5.1. Metodología de Cálculo

Dependiendo de la naturaleza del algoritmo, la importancia se ha determinado mediante dos aproximaciones matemáticas:


- **Modelos Lineales (Ridge, Lasso, LinearSVR):** La importancia se deriva directamente de los coeficientes de regresión estandarizados (β_i). Un mayor valor absoluto del coeficiente indica una mayor sensibilidad de la variable objetivo ante cambios en ese componente.
- **Modelos Basados en Árboles (XGBoost, RandomForest):** Se utiliza la métrica de *Gini Importance* o ganancia de información, que cuantifica la reducción total de la impureza (o error cuadrático) aportada por cada variable en las particiones de los árboles.

5.5.2. Interpretación de Resultados y Predominancia de Componentes

Al observar el comportamiento de los modelos con mayor capacidad de generalización, se identifican patrones de consistencia estadística:

1. **Dominancia del PC7, PC8 y PC1:** En modelos de alto rendimiento como *XGBoost*, *Random Forest*. Esto sugiere que las variables originales relacionadas con la ubicación geoespacial específica y tipología de habitación son los principales vectores de precio en Nueva York.
2. **Consistencia Multimodelo:** Es notable que tanto modelos lineales como no lineales coinciden en la jerarquía de los primeros tres componentes (PC7, PC1 y PC8). Esta convergencia entre diferentes arquitecturas matemáticas refuerza la validez de la selección de características y confirma que la señal predictiva es robusta y no un artefacto de un algoritmo específico.
3. **Componentes Residuales:** Componentes como PC12 o PC6 muestran una importancia cercana a cero en la mayoría de los modelos. Desde una perspectiva matemática, esto indica que dichas dimensiones capturan varianza del dataset original que, aunque relevante para la reconstrucción de los datos, carece de correlación con la variable económica *price*.

Figura 10: Feature Importance



5.6. Evaluación, Diagnóstico y Selección Final

Más allá de las métricas puramente aisladas como el Error Absoluto Medio (MAE) o el R^2 , el protocolo de auditoría incorporó una métrica penalizante diseñada en este estudio: el **Overfitting Gap**. Esta dimensión calculaba la sustracción analítica entre la varianza explicada en la partición de entrenamiento (Train) y la de evaluación (Hold-out). Cualquier modelo superando un salto del 0.05 era clasificado como inestable (memorización de ruido o varianza de sesgo extrema) y descartado categóricamente.

Tabla 8: Resultados comparativos del ecosistema de modelado supervisado

Modelo	CV R^2	Hold-out R^2	MAE (\$)	RMSE (\$)	Gap	Mejores Parámetros
SVR_RBF	0.5673	0.5899	54.30	194.85	-0.0027	C: 1, Gamma: scale
Voting_Assembly	0.5686	0.5866	55.16	193.96	0.0414	w: [0.4, 0.4, 0.2]
XGBoost	0.5672	0.5864	55.41	193.11	0.0288	max_depth: 3, lr: 0.1
RandomForest	0.5627	0.5794	55.49	194.49	0.0760	n_est: 100, depth: 10
Ridge	0.5263	0.5472	57.32	196.29	-0.0199	alpha: 10.0
LinearRegression	0.5263	0.5472	57.32	196.29	-0.0200	-
LinearSVR	0.5263	0.5472	57.32	196.30	-0.0200	C: 1.0
Lasso	0.5242	0.5435	57.22	196.92	-0.0187	alpha: 0.01
Stacking	0.5255	0.5458	57.16	196.71	-0.0194	-
DecisionTree	0.4820	0.5027	59.72	197.97	-0.0051	max_depth: 5
AdaBoost	0.4471	0.4546	62.79	199.04	-0.0063	n_est: 50, lr: 0.1

Modelo Ganador: El algoritmo **Support Vector Regressor con Kernel Radial (SVR_RBF)** se posicionó como el modelo elegido. Su kernel no lineal (*RBF*) probó ser la herramienta para capturar las interacciones geolocalizadas complejas dentro del espacio PCA. Alcanzó un R^2 aproximado del 59 % con un MAE competitivo de \$54.29 dólares y un *Overfitting Gap* prácticamente nulo, certificando matemáticamente su capacidad de generalización algorítmica ante nuevas observaciones.

Para validar la robustez de los modelos, se procedió a realizar un análisis de sus residuos. Este paso es fundamental para asegurar que el modelo ha capturado la estructura subyacente de los datos y que los errores se comportan de manera aleatoria, solo se mostrará el del modelo ganador **SVR con Kernel RBF** pero durante la ejecución se crea una para cada modelo.




Figura 11: Diagnóstico de residuos para el modelo SVR_RBF: (Izquierda) Comparación de valores reales frente a predicciones; (Derecha) Distribución de los errores de predicción.

Como se ve en las gráficas el modelo presenta un comportamiento saludable:

- **Ajuste Lineal:** En el gráfico de valores reales vs. predichos (escala logarítmica), las observaciones se agrupan de forma consistente alrededor de la diagonal de 45 grados, lo que indica una alta capacidad de generalización incluso en las zonas de mayor densidad de precios.
- **Normalidad de Residuos:** La distribución de los errores muestra una forma acampanada centrada en el valor cero. Esto confirma que el modelo no presenta un sesgo sistemático (subestimación o sobreestimación recurrente) y que la transformación logarítmica aplicada inicialmente fue efectiva para estabilizar la varianza.

SVR_RBF ofrece las mejores métricas pero en 40.18s el más costoso. **Ridge** es el más rápido con valores cercanos a 0 pero con $R^2 = 0,54$ pese a ello es el más eficiente (Efficiency = F1/Time). A continuación se muestran todos los tiempo y la eficiencia de los modelos.

Tabla 9: Evaluación Multicriterio: Rendimiento, Coste Temporal y Eficiencia

Modelo	Hold-out R^2	Train Time (s)	Eficiencia (R^2/T)
Ridge	0.5472	0.0001*	5472.000
LinearRegression	0.5471	0.0126	43.420
LinearSVR	0.5057	0.0166	30.463
Lasso	0.5435	0.1233	4.407
DecisionTree	0.5516	0.2597	2.124
XGBoost	0.5864	0.7348	0.798
Stacking	0.5833	0.4565	1.278
RandomForest	0.5794	2.9953	0.193
AdaBoost	0.4546	8.0249	0.056
Voting_Assembly	0.5866	28.4354	0.021
SVR_RBF	0.5899	40.1898	0.015

*Se utiliza un valor infinitesimal para evitar la división por cero.

Como el modelo se va a exportar está métrica no es tan relevante pero si se quisiera reentrenar aumentando el número de datos o variables, cosa recomendada teniendo en cuenta la varianza explicada, sería una métrica a tener en cuenta entre los mejores modelos que superen el umbral objetivo.

6. Despliegue e Interfaz Interactiva

6.1. Arquitectura de Producción (Streamlit)

La finalidad de cualquier ecosistema analítico aplicado es su transferencia al dominio humano mediante una interfaz interpretable. El modelo **SVR_RBF** ganador, la proyección topológica PCA, la matriz de escalado StandardScaler y el propio modelado de segmentación (K-Means) fueron encapsulados matemáticamente y exportados a disco (*Pickle Serialization*).

Este esquema actúa como motor *backend* para una interfaz de usuario completamente dinámica construida bajo la arquitectura Streamlit. La aplicación elimina la necesidad de que los *stakeholders* interactúen vía terminal, ofreciendo en una arquitectura web una experiencia integral unificada, desde tableros de diagnóstico y representaciones biplot del PCA, hasta un simulador *real-time*.

6.2. Estructura Modular del Aplicativo

La interfaz se organiza en un pipeline de siete módulos lógicos que replican la metodología científica seguida en este trabajo:

1. **Panel de Control Central (Dashboard):** Implementado en `app.py`, ofrece una visión macroscópica mediante un **Mapa 3D Global** utilizando la librería *PyDeck*. Representa la densidad de precios mediante columnas de elevación sobre el mapa de NYC en un entorno de tema oscuro (*Dark Mode*).
2. **Módulos de Diagnóstico Estadístico:**
 - *Análisis Univariate:* Visualización de distribuciones mediante histogramas y diagramas de caja.
 - *EDA Interactivo:* Filtros dinámicos por distrito (*neighbourhood_group*) y barrio, con renderizado de mapas de calor.
3. **Documentación del Preprocesamiento y PCA:** Espacio dedicado a la transparencia algorítmica donde se visualizan los *Scree Plots* de varianza explicada y la tabla de pesos (*Loadings*) de las variables originales sobre los componentes.




Figura 12: Interfaz Principal: Visualización geoespacial 3D de la densidad de precios en NYC.

6.3. Visualización Avanzada de Segmentación

En el módulo de Clustering, se integró un análisis de consenso mediante el **Método del Codo** y el **Análisis de Silueta**. La aplicación permite al analista explorar la composición de cada grupo (ej. porcentaje de "Entire home" frente a "Private room" en el Cluster 0) y visualizar la dispersión geográfica en un mapa de dispersión de alta resolución (*Mapbox*).




Figura 13: Distribución espacial de cústers.

6.4. El Motor de Inferencia y Simulación

El módulo `6_Evaluacion_Final_y_Comparacion.py` constituye el núcleo operativo del despliegue. A diferencia de una calculadora estática, este motor ejecuta un flujo de trabajo asíncrono:

- **Captura Geográfica Estricta:** El usuario selecciona la ubicación mediante un mapa interactivo de *Folium*. El sistema extrae las coordenadas (ϕ, λ) y calcula instantáneamente las distancias a puntos estratégicos (Times Square, Central Park y Grand Central Terminal).
- **Transformación en Tiempo Real:** Los *inputs* se someten a *Target Encoding* (para el vecindario) y *One-Hot Encoding* (para el tipo de habitación y el barrio), seguido de la proyección al espacio de las componentes principales mediante la matriz PCA cargada en memoria.
- **Output Dual:** El sistema retorna el precio predicho por el SVR y, simultáneamente, asigna la propiedad a uno de los **perfiles de mercado (Clusters)** identificados, permitiendo al usuario comparar su estimación con la media de su segmento competitivo.

7. Conclusiones y Trabajo Futuro

7.1. Cumplimiento de Objetivos

Las metas delineadas en la fundamentación de este informe, fueron cumplimentadas en su totalidad:

1. **Resolución Predictiva:** Se logró modelar la alta varianza del mercado de Nueva York (donde dominaban patrones de ruido y asimetría temporal severa), absorbiendo un 59 % de la varianza total a través de un algoritmo robusto a sobreajustes (*SVR_RBF*).
2. **Ingeniería Híbrida:** La superación del Baseline se fundamentó mayoritariamente por la codificación logarítmica para lidiar con el MAR detectado y la adición del preprocesamiento de coordenadas Haversine, reducidas vectorialmente en un espacio estable vía PCA.

3. **Conocimiento Latente:** El Clustering brindó la validación de que las interacciones del mercado de alquiler están determinadas sustancialmente por la exclusividad de uso y la distancia a los focos masivos de consumo (*Times Square*, etc.).

7.2. Limitaciones del Estudio

El rigor científico exige el reconocimiento formal de los límites arquitectónicos presentes:

- **Falta de Variabilidad Estacional:** Al operar exclusivamente sobre una instantánea fotográfica del año 2019, es imposible extraer factores de picos de demanda estival, eventos temporales masivos o la subsecuente pandemia global del COVID-19, dictando que el modelo captura estructuras estructurales puras, pero no variaciones macroeconómicas transitorias.
- **Carencia de Contexto Visual o Descriptivo:** En mercados altamente subjetivos, factores no estructurados como la limpieza general inferida por las fotografías de la galería y su descripción textual son predictores ocultos inalcanzables en los datos tabulares disponibles.
- **Variables explicativas:** La adición de variables como m^2 o si consta de instalaciones como puede ser un garaje, piscina o ascensor, al igual que el piso del alojamiento son variables que probablemente aumentaría la varianza explicada.

7.3. Recomendaciones y Trabajo Futuro

Con base en los resultados, el *Action Plan* para futuras iteraciones:

1. **Análisis de Sentimiento Computacional (NLP):** Procesar masivamente el corpus textual de los comentarios empleando modelos de Lenguaje Neuronal masivos (LLMs), agregando un coeficiente de penalización/bonificación basado en polaridad.
2. **Motor de Retroalimentación en Tiempo Real:** Diseñar la arquitectura analítica orientada a flujos y **Event Streams**, re-entrenando pesos dinámicos en los modelos SVR con APIs para adaptar las rentabilidades predichas a shocks de la demanda de alta inmediatez logística.

Referencias

- [1] Dgomonov. (2019). *New York City Airbnb Open Data* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/dgomonov/new-york-city-airbnb-open-data>
- [2] Scikit-learn Team. (2024). *Scikit-learn: Machine Learning in Python*. <https://scikit-learn.org/stable/>
- [3] McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. <https://pandas.pydata.org/>
- [4] Streamlit Developers. (2024). *Streamlit Documentation*. <https://docs.streamlit.io/>
- [5] Scikit-learn Team. (2024). `sklearn.svm.SVR` (Epsilon-Support Vector Regression). <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVR.html>
- [6] Scikit-learn Team. (2024). `sklearn.ensemble.VotingRegressor`. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.VotingRegressor.html>

-
- [7] XGBoost Developers. (2024). `xgboost.XGBRegressor`. https://xgboost.readthedocs.io/en/stable/python/python_api.html#xgboost.XGBRegressor
 - [8] Scikit-learn Team. (2024). `sklearn.ensemble.RandomForestRegressor`. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>
 - [9] Scikit-learn Team. (2024). `sklearn.tree.DecisionTreeRegressor`. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html>
 - [10] Scikit-learn Team. (2024). `sklearn.ensemble.AdaBoostRegressor`. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.AdaBoostRegressor.html>
 - [11] Scikit-learn Team. (2024). `sklearn.linear_model.LinearRegression`. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html
 - [12] Scikit-learn Team. (2024). `sklearn.linear_model.Ridge`. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html
 - [13] Scikit-learn Team. (2024). `sklearn.linear_model.Lasso`. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html
 - [14] Scikit-learn Team. (2024). `sklearn.svm.LinearSVR`. <https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVR.html>
 - [15] Scikit-learn Team. (2024). `sklearn.linear_model.SGDRegressor`. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDRegressor.html
 - [16] Scikit-learn Team. (2024). `sklearn.cluster.KMeans`. <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>
 - [17] Scikit-learn Team. (2024). `sklearn.decomposition.PCA`. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>
 - [18] S. Repogit. (2026). *NYC Airbnb Prediction and Clustering Suite* [Código fuente]. GitHub. https://github.com/Sergio-repogit/NYC_reg_model_clustering